НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ УНИВЕРСИТЕТ «ВЫСШАЯ ШКОЛА ЭКОНОМИКИ»
Дисциплина: «Алгоритмы и структуры данных»

Контрольное домашнее задание

Исследование алгоритмов сжатия Хаффмана и Шеннона-Фано

Выполнил: Мариносян Никита,
студент гр. БПИ151.

Преподаватель: Мицюк А. А.

Москва 2016

Оглавление

Постановка задачи

(1) Реализовать с использованием языка C++ программы для архивирования и разархивирования текстовых файлов. При этом использовать два известных алгоритма кодирования информации:

1. Хаффмана (простой),

2. Шеннона-Фано.
Обе реализации поместить в одном файле main.cpp, содержащем соответствующие методы:

1. метод архивирования, использующий алгоритм Хаффмана, вход: текстовый файл <name>.txt (кодировка UTF-8)
   выход: архивированный файл <name>.haff
2. метод разархивирования, использующий алгоритм Хаффмана, вход: архивированный файл <name>.haff
   выход: разархивированный файл <name>-unz-h.txt (кодировка UTF-8)
3. метод архивирования, использующий алгоритм Шеннона-Фано, вход: текстовый файл <name>.txt (кодировка UTF-8)
   выход: архивированный файл <name>.shan
4. метод разархивирования, использующий алгоритм Шеннона-Фано. вход: архивированный файл <name>.shan
   выход: разархивированный файл <name>-unz-s.txt (кодировка UTF-8)

Выбор алгоритма осуществляется с помощью флага командной строки.

Оба алгоритма работают *в два прохода*. Сначала строится *таблица частот встречаемости символов* в конкретном архивируемом файле (кодируем только те символы из набора допустимых, которые реально встречаются в файле). Затем разными способами строится *кодовое дерево*. По нему и архивируется файл. Для разархивирования алгоритмам потребуется знать таблицу, которая использовалась при архивировании. Соответствующая таблица должна сохраняться в архивном файле в самом его начале и использоваться при разархивировании. В начале пишется количество различных символов *n*, имеющихся в кодируемом файле, а затем *n* пар (код символа UTF-8, битовый код в архиве). Порядок — по убыванию частоты встречаемости символа в кодируемом файле.

(2) Провести вычислительный эксперимент с целью оценки реализованных алгоритмов архивации / разархивации. Оценить количество элементарных операций каждого алгоритма.

Для этого
1. Подготовить тестовый набор из нескольких текстовых файлов разного объема

(20, 40, 60, 80, 100 Кб; 1, 2, 3 Мб — всего 8 файлов) на разных языках (ru, en - кодировка UTF-8) с разным набором символов в каждом файле, а именно:

1. первый набор: символы латинского алфавита и пробел
2. второй набор: символы из первого набора + символы русского алфавита
3. третий набор: символы из второго набора + следующие знаки и

   спецсимволы: знаки арифметики „**+ - * / =**“, знаки препинания „**. , ; : ? !**“, символы„**%@#$&~**‘’, скобки разных типов „**()[]{}**<>“, кавычки„**„“**“),

2. Измерить (экспериментально) количество операций (в рамках модели RAM *(см. лекционный материал)*), выполняемых за время работы (архивирования, разархивирования) каждого алгоритма на нескольких различных (не менее трех) файлах для каждого размера входного файла и набора символов (итого получается 8 * 3 * 3 = 72 эксперимента по архивированию и 72 по разархивированию для каждого алгоритма, т. е. всего минимум 144 * 2 = 288, имеет смысл задуматься об автоматизации). Для повышения достоверности результатов каждый эксперимент *можно* повторить несколько (5-10) раз на различных файлах (с одним возможным набором символов) одного размера с последующим усреднением результата.

(3) Подготовить отчет по итогам работы, содержащий постановку задачи, описание алгоритмов и задействованных структур данных, описание реализации, обобщенные результаты измерения эффективности алгоритмов, описание использованных инструментов (например, если использовались скрипты автоматизации), выводы о соответствии результатов экспериментальной проверки с теоретическими оценками эффективности исследуемых алгоритмов.

Отчет также должен содержать измерения качества архивации (степень сжатия = отношение размеров выходного и входного файлов), оценку связи между степенью сжатия для различных входных файлов (как влияют объем, язык, набор символов, их разнообразие?) и временем работы (количеством операций) для каждого алгоритма.

В отчете необходимо ***явно*** указать, какие части задания были сделаны, а какие нет!

Описание алгоритмов и использованных структур данных

Оба алгоритма схожи по многим параметрам. Вначале подсчитывается частота встречаемости отдельных символов в тексте (первый обход программы). Затем, основываясь на информации о частоте встречаемости каждого символа, разными способами (алгоритмом Хаффмана или Шеннона-Фано) строится бинарное дерево таким образом, что символу с наибольшей частотой соответствует код наименьшей длины. После этого каждый символ исходного текста кодируется соответствующим ему двоичным кодом и записывается в новый файл (второй обход программы).

Алгоритм Хаффмана

После составления таблицы частот встречаемости символов, алгоритм состоит из следующих шагов:

1. Выбрать две вершины с наименьшим весом.

2. Создать новую вершину с весом, равным сумме весов выбранных узлов, и присоединить к ней (с помощью указателей) две выбранные вершины в качестве «детей».

3. Добавить к списку новую вершину, созданную из двух других.

4. Если в списке больше одного узла, то повторить пункты с первого по четвертый

Таким образом, дерево строится снизу вверх, т.е. от листьев к корню.

Алгоритм Шеннона-Фано

Алгоритм отличается способом построения дерева, которое, в отличие от алгоритма Хаффмана, ведется от корня к листьям. После составления таблицы частот встречаемости символов, алгоритм выглядит следующим образом:

1. Символы полученного алфавита разделяются на две части таким образом, чтобы суммарные частоты этих двух частей были максимально близки друг другу.

2. К кодам символов, находящихся в первой части алфавита, приписывается «0», а к кодам символов второй части — «1».

3. Рекурсивно вызывается эта же функция, которая делит полученные части на более маленькие и приписывает соответствующие двоичные цифры к кодам символов, до тех пор, пока в каждой части не останется один элемент.

Структуры данных, использованные при реализации

При реализации вышеописанных алгоритмов использовались следующие структуры данных:

- Дерево — набор связных узлов, имитирующих древовидную структуру. Для реализации созданы классы HuffmanVertex и SFVertex, представляющие собой отдельную вершину дерева, в которой хранится информация о символе, его частоте и “детях”.

- Вектор (vector) - абстрактный тип данных, представляющий собой упорядоченный набор значений, в котором некоторое значение может встречаться более одного раза. Использовался из-за удобства работы (быстрый произвольный доступ к элементам, автоматическое изменение размера при вставке или удалении элементов) и возможности использования стандартной сортировки std::sort.
- Ассоциативный массив (map) - контейнер, который содержит пары ключ-значение с неповторяющимися ключами. Использовался для хранения уникальных для текста символов и соответствующей им частоты.

Вспомогательные функции и классы, использованные при реализации

Класс HuffmanVertex – вспомогательный класс, имитирующий вершину дерева. Полями являются frequency – частота появления символа в тексте и character – сам символ. Также полями являются два указателя на дочерние вершины типа HuffmanVertex*: left_node и right_node.

Класс SFVertex – вспомогательный класс, имитирующий вершину дерева. Полями являются frequency – частота появления символа в тексте, character – сам символ и code – бинарный код данного символа.

Метод getFrequencyMap – вспомогательный метод построения ассоциативного массива и, хранящем информацию о частоте встречаемости символов в тексте, написанном в файле, путь к которому передается методу в качестве параметра. Также используется для подсчета числа символов в файле.

Метод compressFile – вспомогательный метод создания архивированного файла. Посимвольно записывает в новый файл текст исходного файла в соответствующей кодировке, полученной из таблицы кодов. В начале файла записывает необходимую для разархивации информацию: количество символов в тексте исходного файла, количество уникальных символов, сами уникальные символы, длину кодов каждого символа и коды уникального символа.

Метод decompressFile – универсальный метод разархивации файла для обоих алгоритмов. Однако, чтобы соответствовать спецификации, в функции main созданы отдельные методы разархивации для двух алгоритмов, которые вызывают данный метод. Отмечу, что возможность разархивации файла, имеющего расширение .haff с помощью метода для разархивации файла .shan намеренно ограничена (хотя это возможно). Аналогично нельзя разархивировать файл .haff с помощью метода по извлечению архива .shan. Имеет смысл объединить методы разархивации, однако тогда программа не будет соответствовать требованиям задания.

Описание плана эксперимента

При проведении эксперимента я руководствовался следующим планом:

1. Реализовать построение кодов символов алгоритмом Хаффмана, архивацию и разархивацию на основе данного алгоритма на языке C++.
2. Реализовать построение кодов символов алгоритмом Шеннона-Фано, архивацию и разархивацию на основе данного алгоритма на языке C++.
3. С помощью программы на языке Java подготовить тестовый набор из 72 файлов, как написано в задании.
4. Провести тесты по архивации и разархивации каждого файла с помощью двух алгоритмов (всего 72*2*2 = 288 тестов) и получить значения количества элементарных операций для каждого теста.
5. Основываясь на результатах тестов, построить графики и таблицы, требуемые в задании.
6. Составить отчет о проделанной работе, в котором произвести сравнительный анализ методов и сделать основные выводы.

Все пункты данного плана были выполнены. Программа соответствует всем требованиям задания.

Генерация тестовых файлов и их размер

Исполняемый файл генерации тестовых файлов (Main.jar) и сами тестовые файлы можно найти в архиве с КДЗ в папке TestingFiles. Исполняемый файл генерирует тестовые файлы, основываясь на русскоязычном и англоязычном текстах модернистского романа «Улисс» ирландского писателя Джеймса Джойса (файлы *set1.txt) и выбирая случайные символа из соответствующих алфавитов (файлы *set2.txt и *set3.txt). Ввиду особенностей программной реализации генерации тестовых файлов, их размер может незначительно отличаться от требуемых, однако эта разница очень мала и не влияет на результаты эксперимента.

Способ подсчета операций

Для подсчета количества элементарных операций в файле «utilities.h» была создана глобальная переменная «operations». В методах, реализующих каждый из алгоритмов (в том числе вспомогательных, записи в файл и чтения из него), было подсчитано количество элементарных операций, и переменная «operations» увеличивалась на на их число с помощью оператора «+=». С целью повышения эффективности работы программы увеличение глобальной переменной производилось не сразу после осуществления элементарных операций, а после небольших участков кода, в которых было посчитано их число. Каждая стандартная операция («+», «-», «=», «&», «*» и т.д.) считалась за одну элементарную. Методы стандартной библиотеки также считались за одну операцию. Не считались за операцию обращение по индексу и вызов стандартных «свойств» (например .size()). Замечу, что т.к. построение графиков и таблиц ведется относительно конкретной программы, то вне зависимости от способа подсчета операций результат будет один и тот же.

Результаты эксперимента

С помощью скрипта, вызывающего одну из четырех функций архивации/разархивации для файлов разного размера, всего было проведено 288 тестов. Ниже приведена таблица с полученными в ходе эксперимента результатами (файл «All Tests.xlsx»). В колонке “File” первое число соответствует вызываемому методу (1/2/3/4 см. п. «Постановка задачи»), затем идет размер файла, алфавит и номер набора. В колонке “operations” содержится количество элементарных операций для данного файла.

File	operations
1 20Kb_EN_set1.txt	1010030
1 20Kb_EN_RU_set1.txt	1121109
1 20Kb_EN_RU_S_set1.txt	1105603
1 40Kb_EN_set1.txt	2017461
1 40Kb_EN_RU_set1.txt	2246063
1 40Kb_EN_RU_S_set1.txt	2208612
1 60Kb_EN_set1.txt	3015377
1 60Kb_EN_RU_set1.txt	3366131
1 60Kb_EN_RU_S_set1.txt	3298348
1 80Kb_EN_set1.txt	4036158
1 80Kb_EN_RU_set1.txt	4480058
1 80Kb_EN_RU_S_set1.txt	4402424
1 100Kb_EN_set1.txt	5032195
1 100Kb_EN_RU_set1.txt	5591828
1 100Kb_EN_RU_S_set1.txt	5491774
1 1Mb_EN_set1.txt	53790587
1 1Mb_EN_RU_set1.txt	57511405
1 1Mb_EN_RU_S_set1.txt	56436570
1 2Mb_EN_set1.txt	104060159
1 2Mb_EN_RU_set1.txt	116978079
1 2Mb_EN_RU_S_set1.txt	114369882
1 3Mb_EN_set1.txt	154020820
1 3Mb_EN_RU_set1.txt	173543458
1 3Mb_EN_RU_S_set1.txt	170357208
3 20Kb_EN_set1.txt	1014019
3 20Kb_EN_RU_set1.txt	1127494
3 20Kb_EN_RU_S_set1.txt	1109987
3 40Kb_EN_set1.txt	2025347
3 40Kb_EN_RU_set1.txt	2258035

3 40Kb_EN_RU_S_set1.txt	2213471
3 60Kb_EN_set1.txt	3016602
3 60Kb_EN_RU_set1.txt	3380376
3 60Kb_EN_RU_S_set1.txt	3305293
3 80Kb_EN_set1.txt	4049831
3 80Kb_EN_RU_set1.txt	4500244
3 80Kb_EN_RU_S_set1.txt	4408325
3 100Kb_EN_set1.txt	5033977
3 100Kb_EN_RU_set1.txt	5616356
3 100Kb_EN_RU_S_set1.txt	5498095
3 1Mb_EN_set1.txt	53874275
3 1Mb_EN_RU_set1.txt	57735084
3 1Mb_EN_RU_S_set1.txt	56553562
3 2Mb_EN_set1.txt	104147141
3 2Mb_EN_RU_set1.txt	117087897
3 2Mb_EN_RU_S_set1.txt	114465851
3 3Mb_EN_set1.txt	154428388
3 3Mb_EN_RU_set1.txt	174288465
3 3Mb_EN_RU_S_set1.txt	170465973
2 20Kb_EN_set1.haff	842006
2 20Kb_EN_RU_set1.haff	937130
2 20Kb_EN_RU_S_set1.haff	924616
2 40Kb_EN_set1.haff	1684316
2 40Kb_EN_RU_set1.haff	1882660
2 40Kb_EN_RU_S_set1.haff	1852522
2 60Kb_EN_set1.haff	2518257
2 60Kb_EN_RU_set1.haff	2823983
2 60Kb_EN_RU_S_set1.haff	2768945
2 80Kb_EN_set1.haff	3372307
2 80Kb_EN_RU_set1.haff	3759960
2 80Kb_EN_RU_S_set1.haff	3698068
2 100Kb_EN_set1.haff	4204581
2 100Kb_EN_RU_set1.haff	4694131
2 100Kb_EN_RU_S_set1.haff	4614271
2 1Mb_EN_set1.haff	45068253
2 1Mb_EN_RU_set1.haff	48339192
2 1Mb_EN_RU_S_set1.haff	47480821

2 2Mb_EN_set1.haff	87040525
2 2Mb_EN_RU_set1.haff	98404931
2 2Mb_EN_RU_S_set1.haff	96284719
2 3Mb_EN_set1.haff	128740993
2 3Mb_EN_RU_set1.haff	145917541
2 3Mb_EN_RU_S_set1.haff	143382386
4 20Kb_EN_set1.shan	844683
4 20Kb_EN_RU_set1.shan	940178
4 20Kb_EN_RU_S_set1.shan	925509
4 40Kb_EN_set1.shan	1690452
4 40Kb_EN_RU_set1.shan	1890400
4 40Kb_EN_RU_S_set1.shan	1853722
4 60Kb_EN_set1.shan	2518488
4 60Kb_EN_RU_set1.shan	2833741
4 60Kb_EN_RU_S_set1.shan	2771696
4 80Kb_EN_set1.shan	3383537
4 80Kb_EN_RU_set1.shan	3775000
4 80Kb_EN_RU_S_set1.shan	3700011
4 100Kb_EN_set1.shan	4205311
4 100Kb_EN_RU_set1.shan	4712915
4 100Kb_EN_RU_S_set1.shan	4616661
4 1Mb_EN_set1.shan	45141276
4 1Mb_EN_RU_set1.shan	48532801
4 1Mb_EN_RU_S_set1.shan	47579804
4 2Mb_EN_set1.shan	87116373
4 2Mb_EN_RU_set1.shan	98498498
4 2Mb_EN_RU_S_set1.shan	96365226
4 3Mb_EN_set1.shan	129098930
4 3Mb_EN_RU_set1.shan	146569882
4 3Mb_EN_RU_S_set1.shan	143473966
1 20Kb_EN_set2.txt	1258949
1 20Kb_EN_RU_set2.txt	1253480
1 20Kb_EN_RU_S_set2.txt	1325861
1 40Kb_EN_set2.txt	2513065
1 40Kb_EN_RU_set2.txt	2486288
1 40Kb_EN_RU_S_set2.txt	2632013
1 60Kb_EN_set2.txt	3767629

1 60Kb_EN_RU_set2.txt	3726446
1 60Kb_EN_RU_S_set2.txt	3941278
1 80Kb_EN_set2.txt	5022489
1 80Kb_EN_RU_set2.txt	4964886
1 80Kb_EN_RU_S_set2.txt	5252394
1 100Kb_EN_set2.txt	6277047
1 100Kb_EN_RU_set2.txt	6202187
1 100Kb_EN_RU_S_set2.txt	6553136
1 1Mb_EN_set2.txt	64268237
1 1Mb_EN_RU_set2.txt	63433631
1 1Mb_EN_RU_S_set2.txt	67041624
1 2Mb_EN_set2.txt	128542405
1 2Mb_EN_RU_set2.txt	126908528
1 2Mb_EN_RU_S_set2.txt	134006510
1 3Mb_EN_set2.txt	192814864
1 3Mb_EN_RU_set2.txt	190342712
1 3Mb_EN_RU_S_set2.txt	201092068
3 20Kb_EN_set2.txt	1260803
3 20Kb_EN_RU_set2.txt	1261148
3 20Kb_EN_RU_S_set2.txt	1330262
3 40Kb_EN_set2.txt	2516040
3 40Kb_EN_RU_set2.txt	2499506
3 40Kb_EN_RU_S_set2.txt	2637513
3 60Kb_EN_set2.txt	3771342
3 60Kb_EN_RU_set2.txt	3746055
3 60Kb_EN_RU_S_set2.txt	3947988
3 80Kb_EN_set2.txt	5026735
3 80Kb_EN_RU_set2.txt	4992402
3 80Kb_EN_RU_S_set2.txt	5260600
3 100Kb_EN_set2.txt	6282047
3 100Kb_EN_RU_set2.txt	6236532
3 100Kb_EN_RU_S_set2.txt	6562104
3 1Mb_EN_set2.txt	64282223
3 1Mb_EN_RU_set2.txt	63670531
3 1Mb_EN_RU_S_set2.txt	67099794
3 2Mb_EN_set2.txt	128561736
3 2Mb_EN_RU_set2.txt	127361807

3 2Mb_EN_RU_S_set2.txt	134113872
3 3Mb_EN_set2.txt	192841164
3 3Mb_EN_RU_set2.txt	191010420
3 3Mb_EN_RU_S_set2.txt	201251932
2 20Kb_EN_set2.haff	1061135
2 20Kb_EN_RU_set2.haff	1053126
2 20Kb_EN_RU_S_set2.haff	1115964
2 40Kb_EN_set2.haff	2120539
2 40Kb_EN_RU_set2.haff	2093746
2 40Kb_EN_RU_S_set2.haff	2221623
2 60Kb_EN_set2.haff	3180332
2 60Kb_EN_RU_set2.haff	3140842
2 60Kb_EN_RU_S_set2.haff	3329888
2 80Kb_EN_set2.haff	4240372
2 80Kb_EN_RU_set2.haff	4186431
2 80Kb_EN_RU_S_set2.haff	4439763
2 100Kb_EN_set2.haff	5300148
2 100Kb_EN_RU_set2.haff	5231007
2 100Kb_EN_RU_S_set2.haff	5540749
2 1Mb_EN_set2.haff	54288665
2 1Mb_EN_RU_set2.haff	53550969
2 1Mb_EN_RU_S_set2.haff	56745737
2 2Mb_EN_set2.haff	108584971
2 2Mb_EN_RU_set2.haff	107143938
2 2Mb_EN_RU_S_set2.haff	113431038
2 3Mb_EN_set2.haff	162879817
2 3Mb_EN_RU_set2.haff	160701092
2 3Mb_EN_RU_S_set2.haff	170221886
4 20Kb_EN_set2.shan	1062677
4 20Kb_EN_RU_set2.shan	1058201
4 20Kb_EN_RU_S_set2.shan	1117679
4 40Kb_EN_set2.shan	2123055
4 40Kb_EN_RU_set2.shan	2103713
4 40Kb_EN_RU_S_set2.shan	2224229
4 60Kb_EN_set2.shan	3183459
4 60Kb_EN_RU_set2.shan	3156427
4 60Kb_EN_RU_S_set2.shan	3333575

4 80Kb_EN_set2.shan	4243993
4 80Kb_EN_RU_set2.shan	4208937
4 80Kb_EN_RU_S_set2.shan	4444779
4 100Kb_EN_set2.shan	5304438
4 100Kb_EN_RU_set2.shan	5259543
4 100Kb_EN_RU_S_set2.shan	5546423
4 1Mb_EN_set2.shan	54300833
4 1Mb_EN_RU_set2.shan	53757756
4 1Mb_EN_RU_S_set2.shan	56794707
4 2Mb_EN_set2.shan	108601900
4 2Mb_EN_RU_set2.shan	107541151
4 2Mb_EN_RU_S_set2.shan	113523279
4 3Mb_EN_set2.shan	162902859
4 3Mb_EN_RU_set2.shan	161287019
4 3Mb_EN_RU_S_set2.shan	170360335
1 20Kb_EN_set3.txt	1258586
1 20Kb_EN_RU_set3.txt	1249209
1 20Kb_EN_RU_S_set3.txt	1325857
1 40Kb_EN_set3.txt	2513821
1 40Kb_EN_RU_set3.txt	2485615
1 40Kb_EN_RU_S_set3.txt	2632069
1 60Kb_EN_set3.txt	3768006
1 60Kb_EN_RU_set3.txt	3732213
1 60Kb_EN_RU_S_set3.txt	3949185
1 80Kb_EN_set3.txt	5022564
1 80Kb_EN_RU_set3.txt	4959625
1 80Kb_EN_RU_S_set3.txt	5250231
1 100Kb_EN_set3.txt	6277730
1 100Kb_EN_RU_set3.txt	6200621
1 100Kb_EN_RU_S_set3.txt	6547398
1 1Mb_EN_set3.txt	64268971
1 1Mb_EN_RU_set3.txt	63427096
1 1Mb_EN_RU_S_set3.txt	67062107
1 2Mb_EN_set3.txt	128545865
1 2Mb_EN_RU_set3.txt	126841407
1 2Mb_EN_RU_S_set3.txt	134037554
1 3Mb_EN_set3.txt	192819297

1 3Mb_EN_RU_set3.txt	190308433
1 3Mb_EN_RU_S_set3.txt	201021474
3 20Kb_EN_set3.txt	1260722
3 20Kb_EN_RU_set3.txt	1256281
3 20Kb_EN_RU_S_set3.txt	1330337
3 40Kb_EN_set3.txt	2516261
3 40Kb_EN_RU_set3.txt	2501182
3 40Kb_EN_RU_S_set3.txt	2637585
3 60Kb_EN_set3.txt	3771500
3 60Kb_EN_RU_set3.txt	3750634
3 60Kb_EN_RU_S_set3.txt	3956499
3 80Kb_EN_set3.txt	5026518
3 80Kb_EN_RU_set3.txt	4980963
3 80Kb_EN_RU_S_set3.txt	5258581
3 100Kb_EN_set3.txt	6282203
3 100Kb_EN_RU_set3.txt	6231644
3 100Kb_EN_RU_S_set3.txt	6557187
3 1Mb_EN_set3.txt	64283346
3 1Mb_EN_RU_set3.txt	63660015
3 1Mb_EN_RU_S_set3.txt	67118862
3 2Mb_EN_set3.txt	128562776
3 2Mb_EN_RU_set3.txt	127299549
3 2Mb_EN_RU_S_set3.txt	134150630
3 3Mb_EN_set3.txt	192844393
3 3Mb_EN_RU_set3.txt	190980481
3 3Mb_EN_RU_S_set3.txt	201187583
2 20Kb_EN_set3.haff	1060855
2 20Kb_EN_RU_set3.haff	1049363
2 20Kb_EN_RU_S_set3.haff	1115898
2 40Kb_EN_set3.haff	2121225
2 40Kb_EN_RU_set3.haff	2093159
2 40Kb_EN_RU_S_set3.haff	2221482
2 60Kb_EN_set3.haff	3180671
2 60Kb_EN_RU_set3.haff	3145892
2 60Kb_EN_RU_S_set3.haff	3336797
2 80Kb_EN_set3.haff	4240438
2 80Kb_EN_RU_set3.haff	4181782

2 80Kb_EN_RU_S_set3.haff	4437901
2 100Kb_EN_set3.haff	5300759
2 100Kb_EN_RU_set3.haff	5229634
2 100Kb_EN_RU_S_set3.haff	5535583
2 1Mb_EN_set3.haff	54289267
2 1Mb_EN_RU_set3.haff	53545194
2 1Mb_EN_RU_S_set3.haff	56763697
2 2Mb_EN_set3.haff	108588049
2 2Mb_EN_RU_set3.haff	107084883
2 2Mb_EN_RU_S_set3.haff	113457709
2 3Mb_EN_set3.haff	162883745
2 3Mb_EN_RU_set3.haff	160670914
2 3Mb_EN_RU_S_set3.haff	170160817
4 20Kb_EN_set3.shan	1062587
4 20Kb_EN_RU_set3.shan	1053937
4 20Kb_EN_RU_S_set3.shan	1117637
4 40Kb_EN_set3.shan	2123245
4 40Kb_EN_RU_set3.shan	2105197
4 40Kb_EN_RU_S_set3.shan	2224145
4 60Kb_EN_set3.shan	3183623
4 60Kb_EN_RU_set3.shan	3160469
4 60Kb_EN_RU_S_set3.shan	3340995
4 80Kb_EN_set3.shan	4243829
4 80Kb_EN_RU_set3.shan	4198895
4 80Kb_EN_RU_S_set3.shan	4443037
4 100Kb_EN_set3.shan	5304587
4 100Kb_EN_RU_set3.shan	5255243
4 100Kb_EN_RU_S_set3.shan	5542015
4 1Mb_EN_set3.shan	54301815
4 1Mb_EN_RU_set3.shan	53748459
4 1Mb_EN_RU_S_set3.shan	56811446
4 2Mb_EN_set3.shan	108602783
4 2Mb_EN_RU_set3.shan	107486339
4 2Mb_EN_RU_S_set3.shan	113555015
4 3Mb_EN_set3.shan	162905714
4 3Mb_EN_RU_set3.shan	161260635
4 3Mb_EN_RU_S_set3.shan	170304809

Построение графиков производилось по таблицам, приведенным в файле «Graphs.xlsx» (там же можно найти и сами графики). EN – набор символов на латинице и пробел. EN_RU – набор символов на латинице, кириллице и пробел. EN_RU_S – набор символов на латинице, кириллице, пробел и другие символы. Huffman compression/decompression – архивация/разархивация алгоритмом Хаффмана. Shannon-Fano compression/decompression – архивация/разархивация алгоритмом Шеннона-Фано.

- Зависимость количества операций (ось OY) от размера файла (ось OX) и размера набора символов (цвет линии) для каждого алгоритма архивирования и разархивирования:

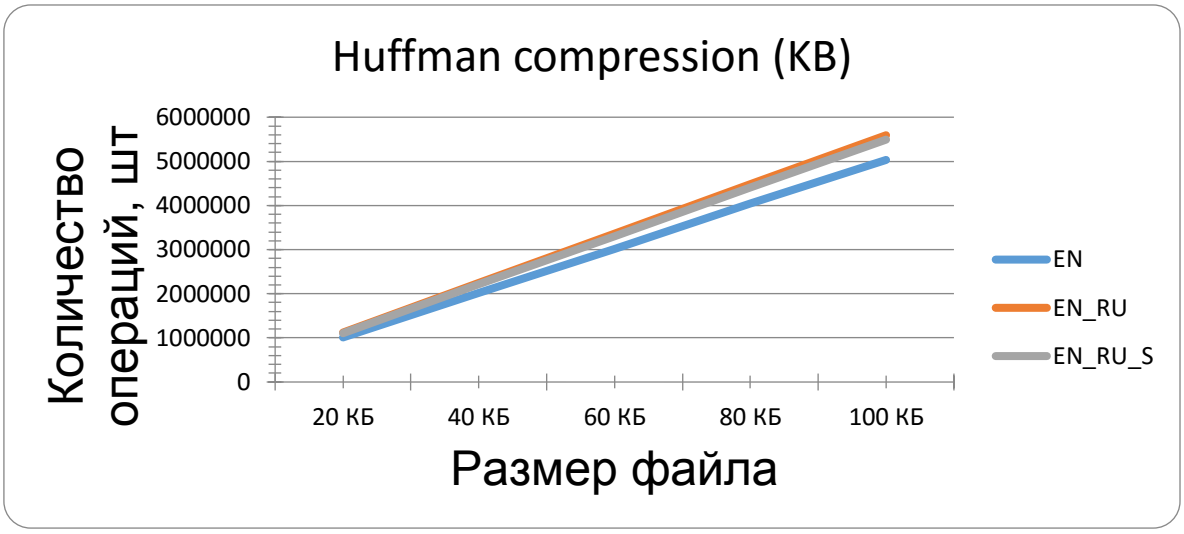

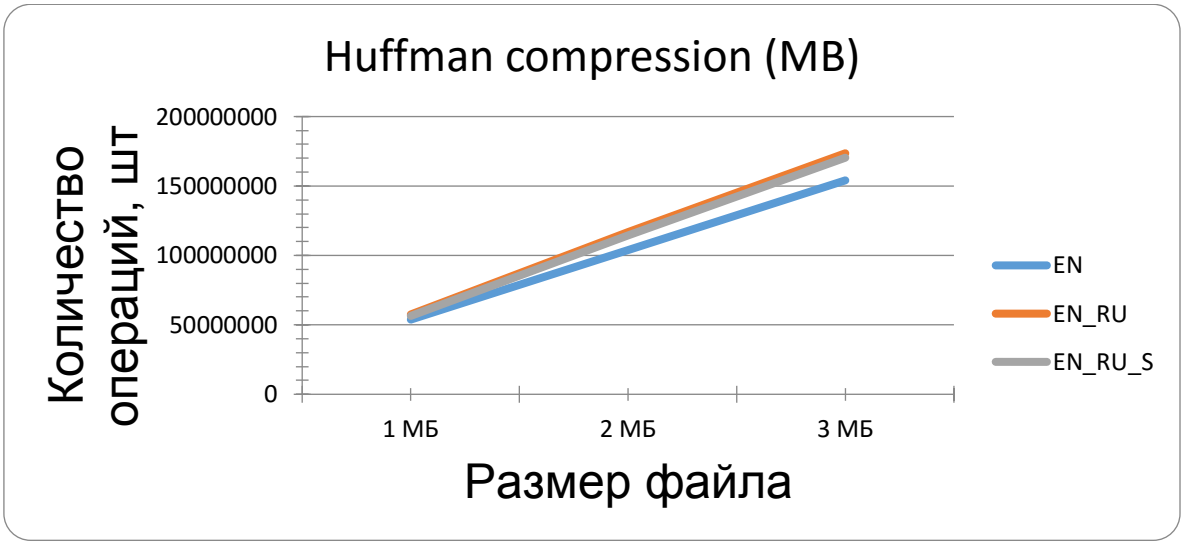

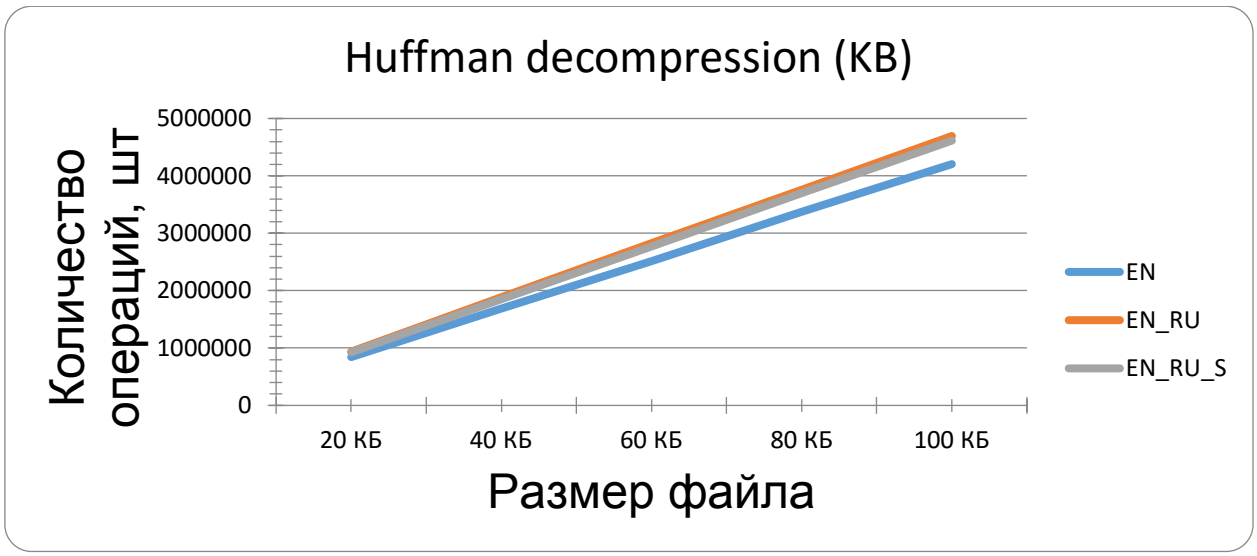
Huffman decompression (KB)
Количество операций, шт
5000000
4000000
3000000
2000000
1000000
0
20 КБ
40 КБ
60 КБ
80 КБ
100 КБ
Размер файла
EN
EN_RU
EN_RU_S

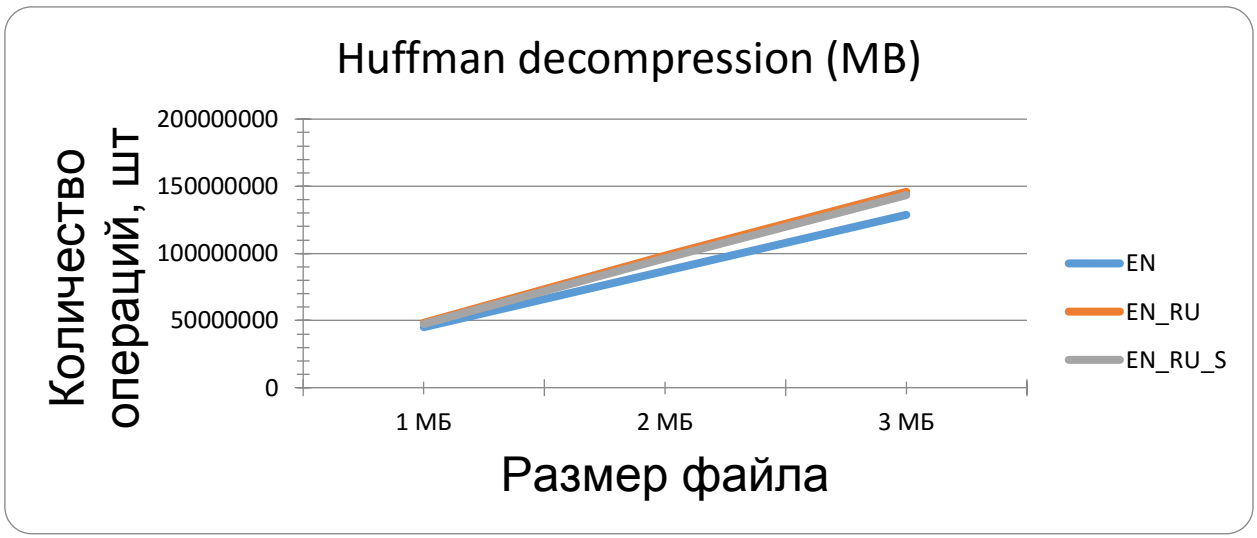
Huffman decompression (MB)
Количество операций, шт
200000000
150000000
100000000
50000000
0
1 МБ
2 МБ
3 МБ
Размер файла
EN
EN_RU
EN_RU_S

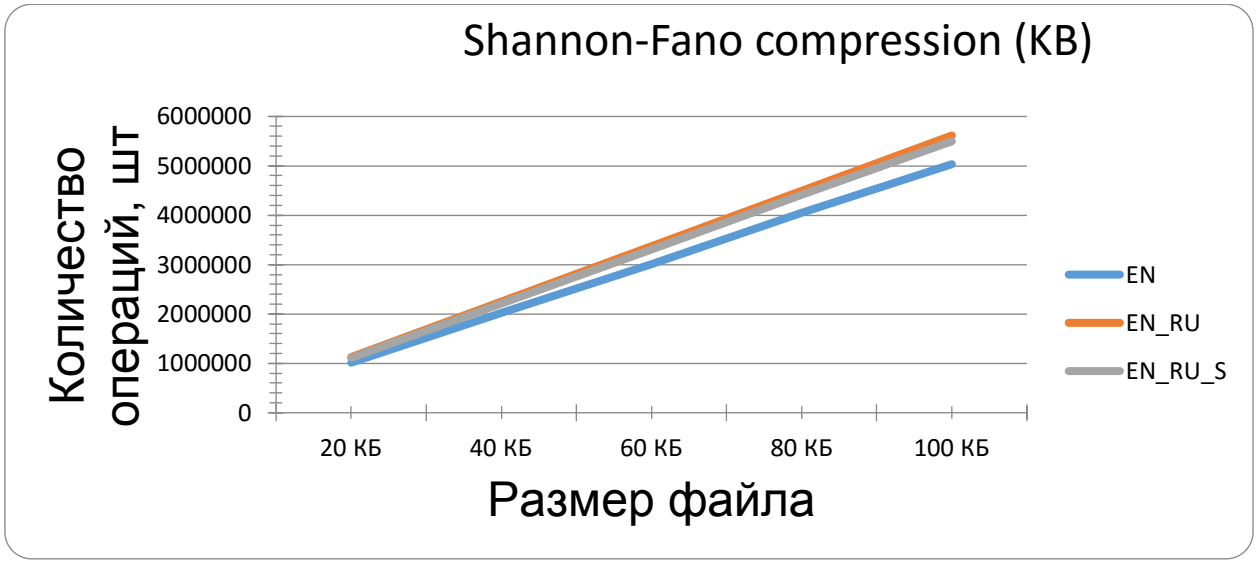
Shannon-Fano compression (KB)
Количество операций, шт
6000000
5000000
4000000
3000000
2000000
1000000
0
20 КБ
40 КБ
60 КБ
80 КБ
100 КБ
Размер файла
EN
EN_RU
EN_RU_S

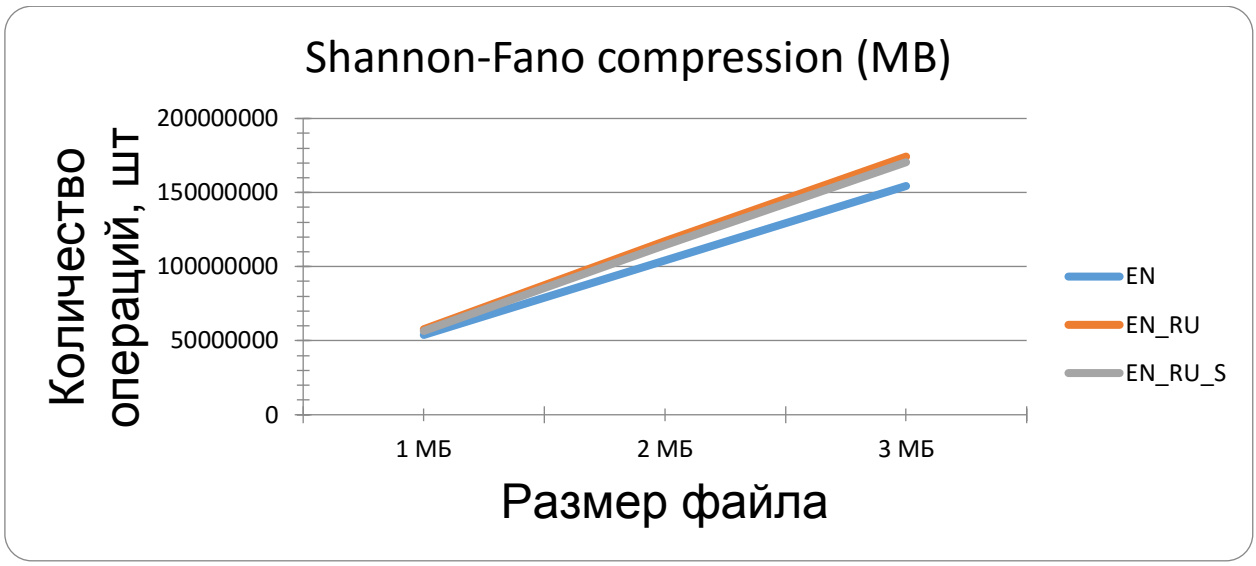

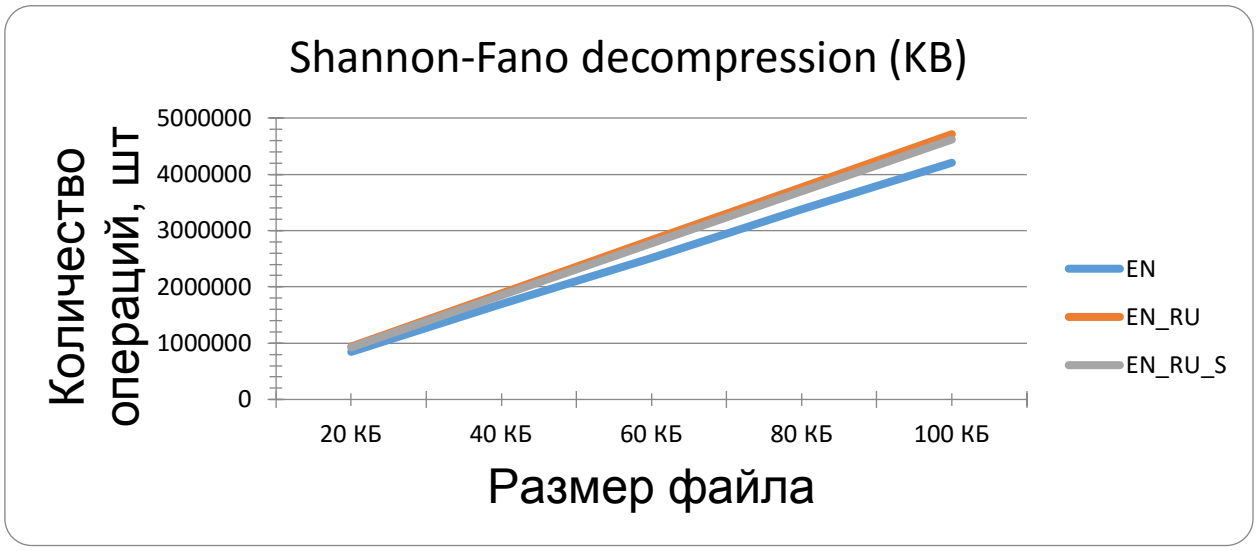

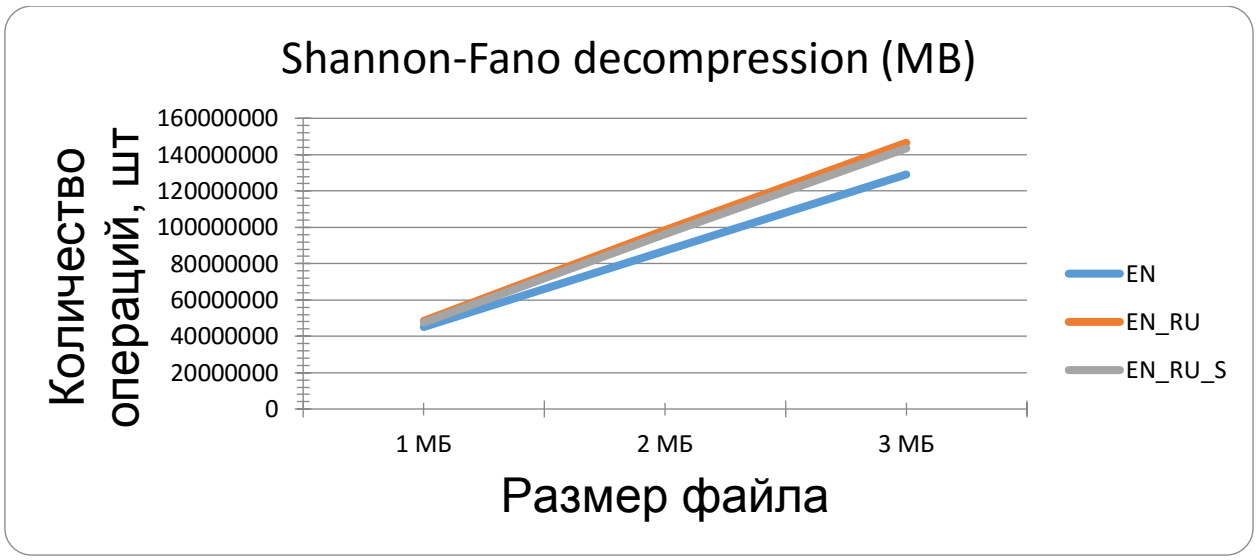

- Зависимость количества операций (ось OY) от размера файла (ось OX), и используемого алгоритма (цвет линии) для каждого набора символов:

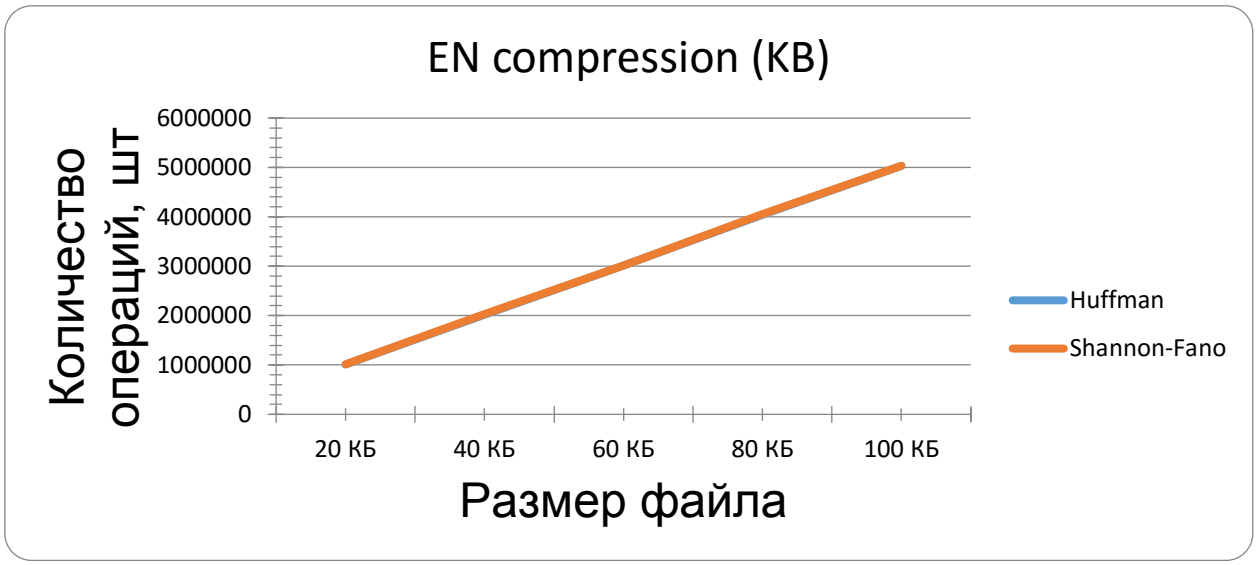
EN compression (KB)
Количество операций, шт
6000000
5000000
4000000
3000000
2000000
1000000
0
20 КБ
40 КБ
60 КБ
80 КБ
100 КБ
Размер файла
Huffman
Shannon-Fano

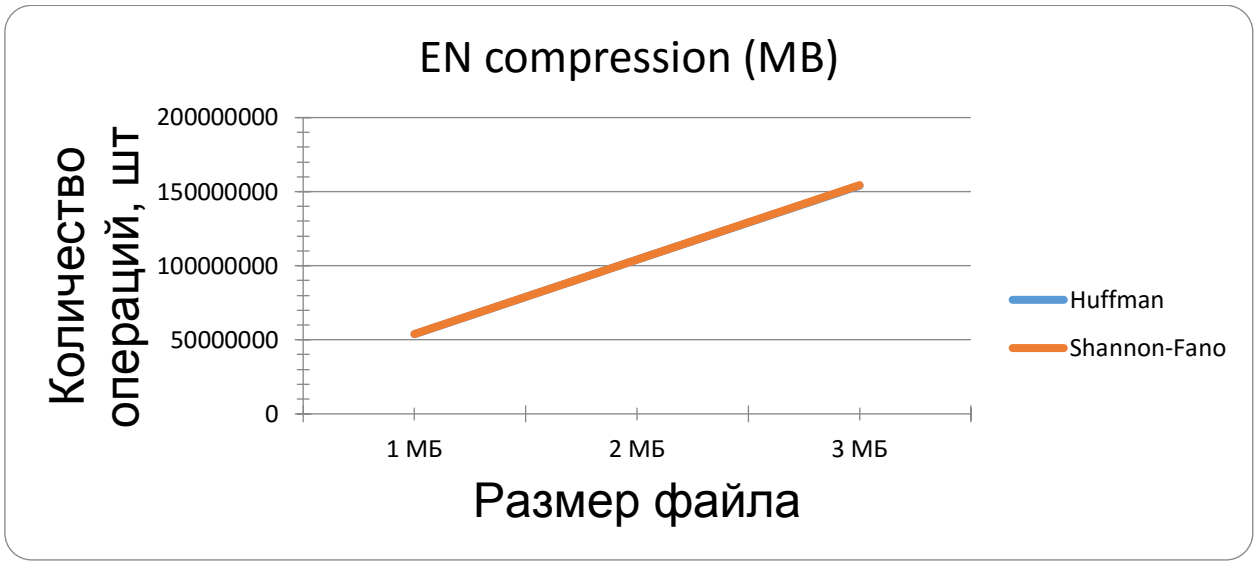
EN compression (MB)
Количество операций, шт
200000000
150000000
100000000
50000000
0
1 МБ
2 МБ
3 МБ
Размер файла
Huffman
Shannon-Fano

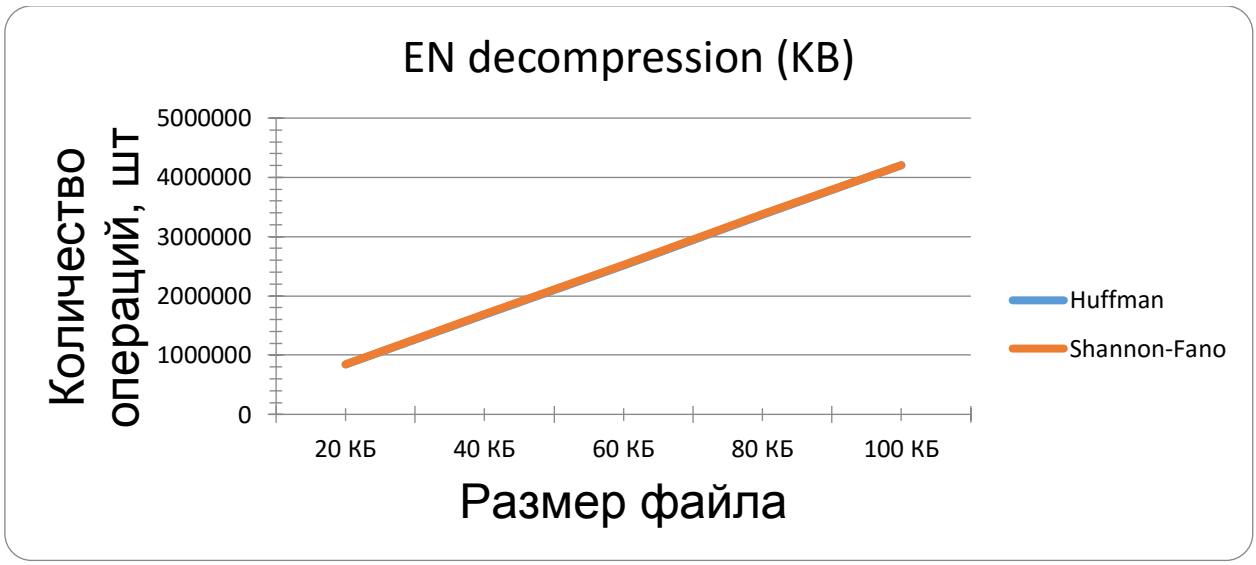
EN decompression (KB)
Количество операций, шт
5000000
4000000
3000000
2000000
1000000
0
20 КБ
40 КБ
60 КБ
80 КБ
100 КБ
Размер файла
Huffman
Shannon-Fano

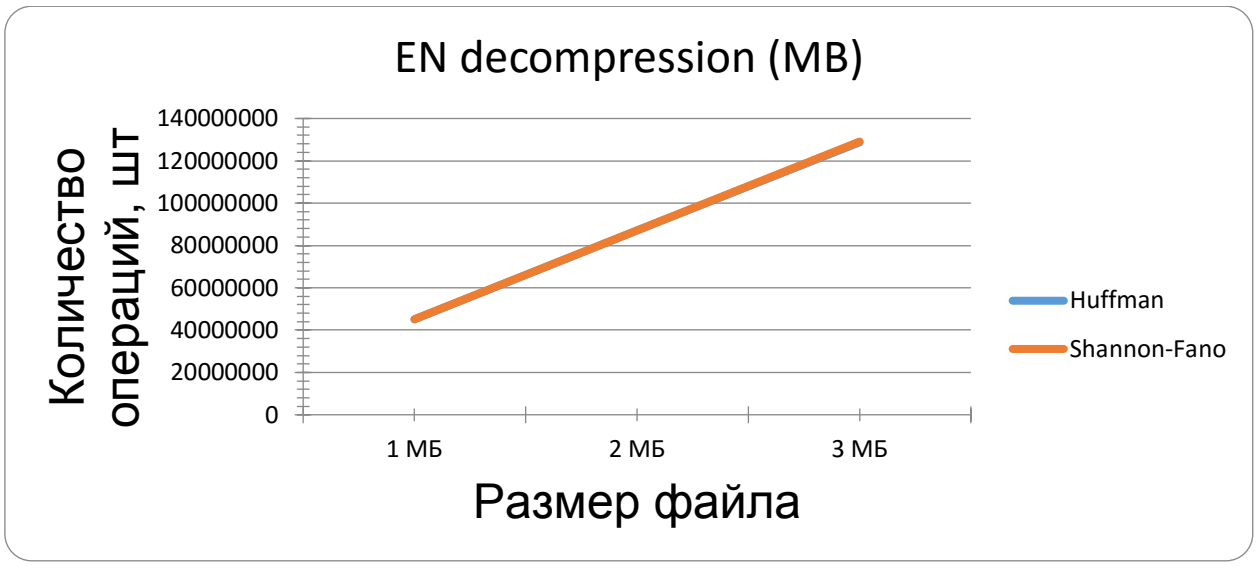
EN decompression (MB)
Количество операций, шт
140000000
120000000
100000000
80000000
60000000
40000000
20000000
0
1 МБ
2 МБ
3 МБ
Размер файла
Huffman
Shannon-Fano

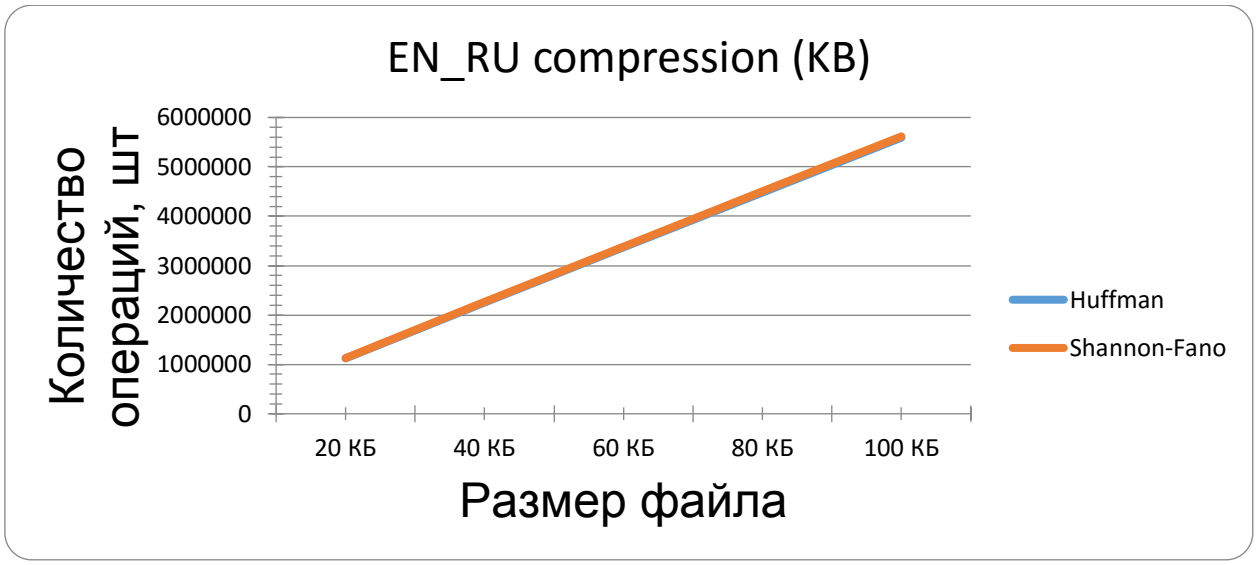
EN_RU compression (KB)
Количество операций, шт
6000000
5000000
4000000
3000000
2000000
1000000
0
20 КБ
40 КБ
60 КБ
80 КБ
100 КБ
Размер файла
Huffman
Shannon-Fano

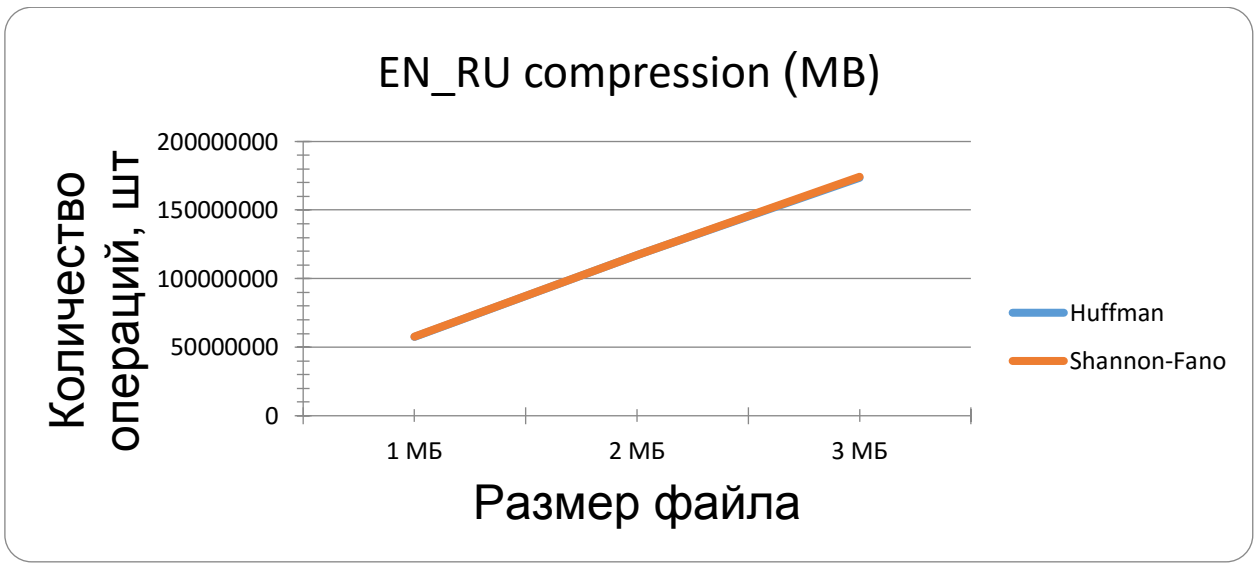
EN_RU compression (MB)
Количество операций, шт
200000000
150000000
100000000
50000000
0
1 МБ
2 МБ
3 МБ
Размер файла
Huffman
Shannon-Fano

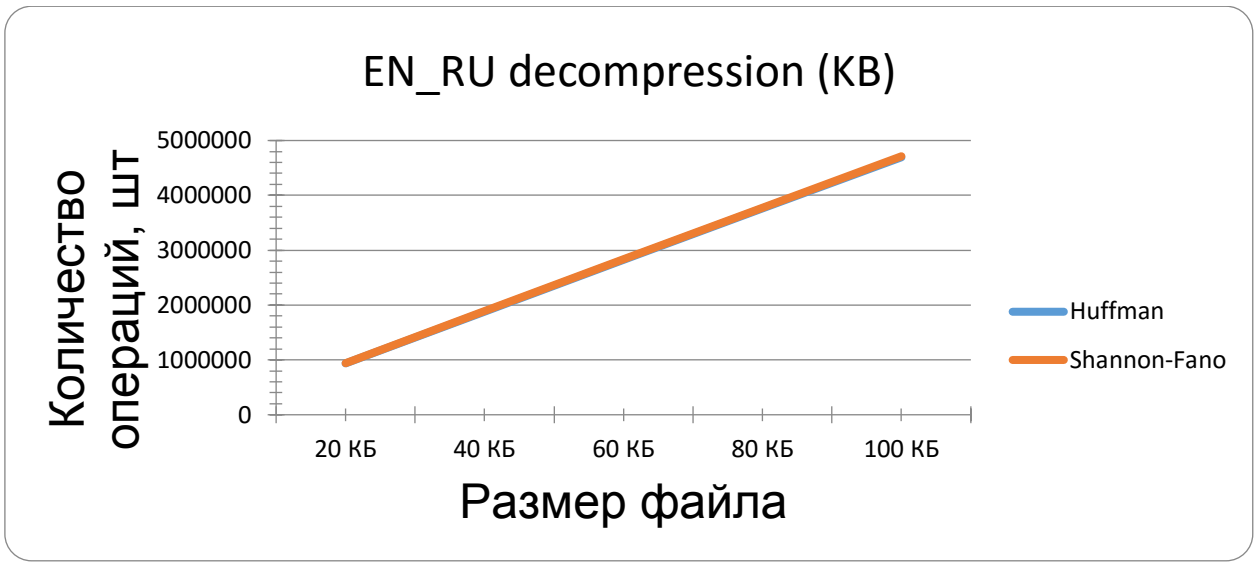
EN_RU decompression (KB)
Количество операций, шт
5000000
4000000
3000000
2000000
1000000
0
20 КБ
40 КБ
60 КБ
80 КБ
100 КБ
Размер файла
Huffman
Shannon-Fano

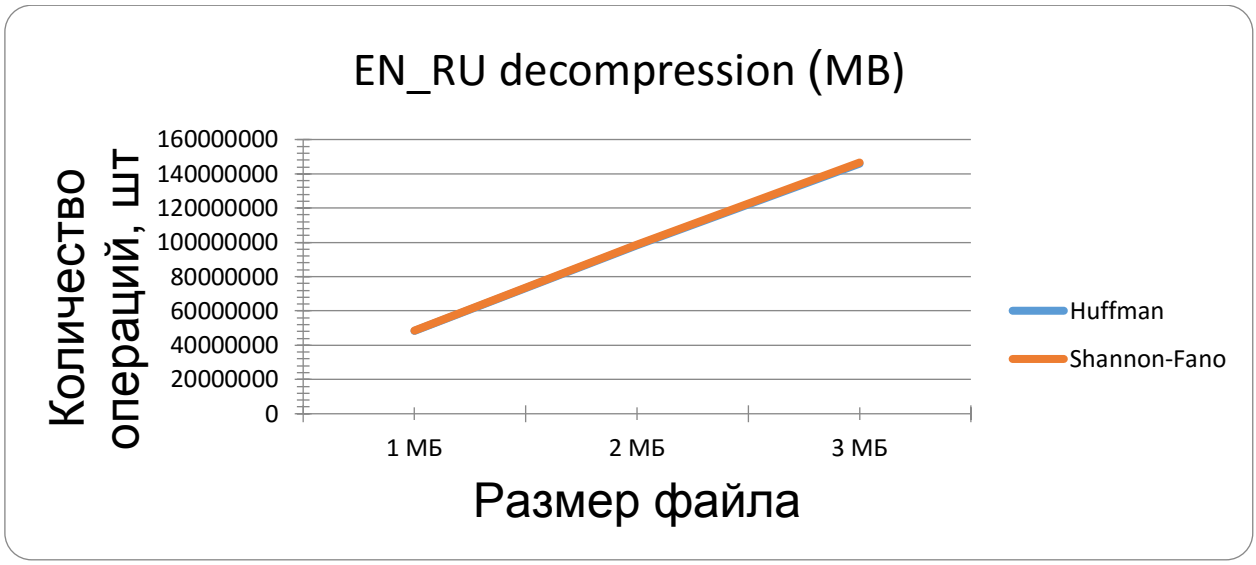
EN_RU decompression (MB)
Количество операций, шт
160000000
140000000
120000000
100000000
80000000
60000000
40000000
20000000
0
1 МБ
2 МБ
3 МБ
Размер файла
Huffman
Shannon-Fano

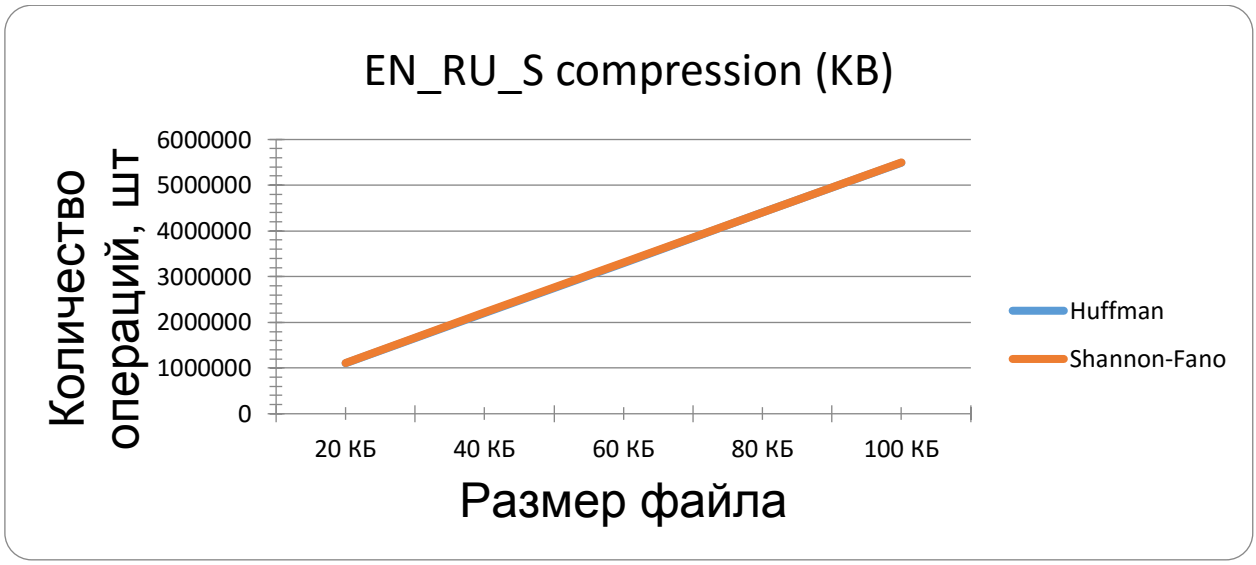
EN_RU_S compression (KB)
Количество операций, шт
6000000
5000000
4000000
3000000
2000000
1000000
0
20 КБ
40 КБ
60 КБ
80 КБ
100 КБ
Размер файла
Huffman
Shannon-Fano

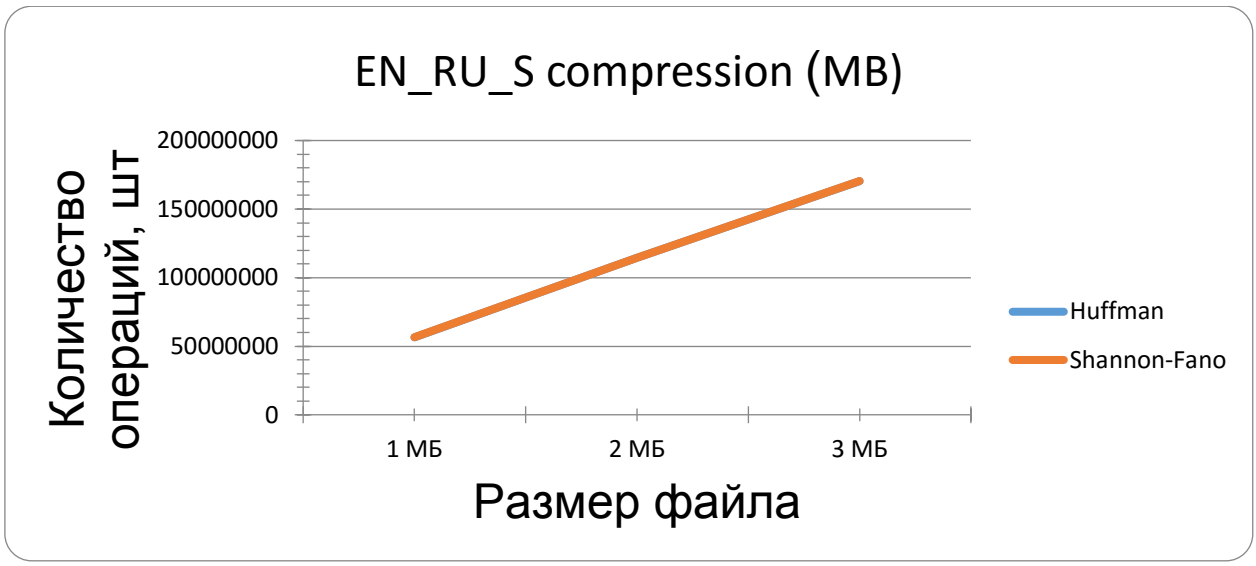
EN_RU_S compression (MB)
Количество операций, шт
200000000
150000000
100000000
50000000
0
1 МБ
2 МБ
3 МБ
Размер файла
Huffman
Shannon-Fano

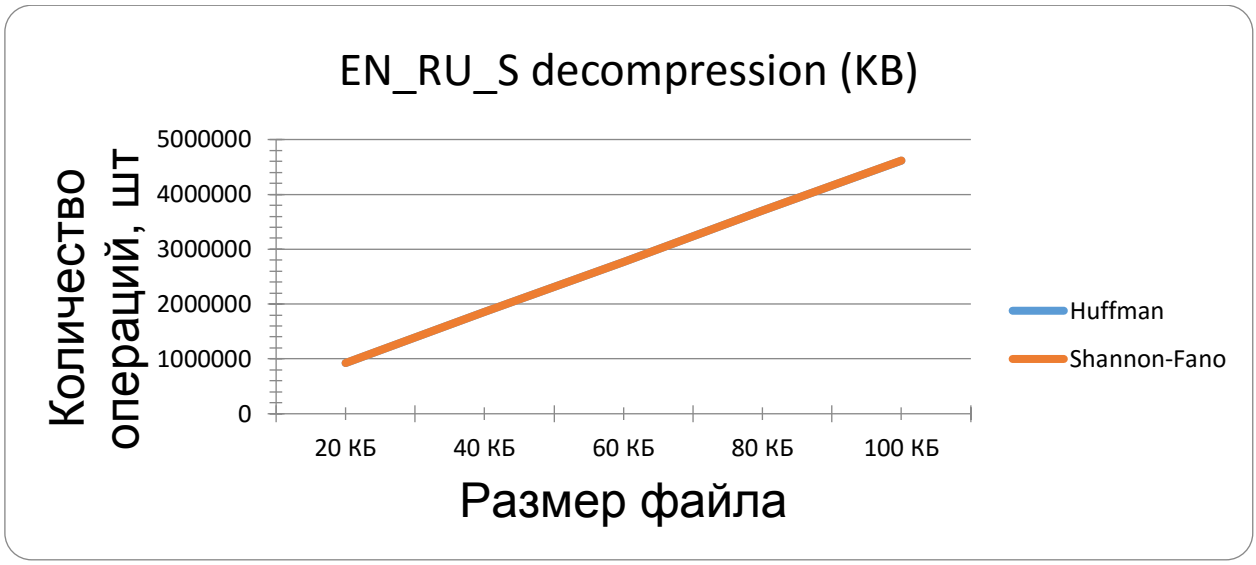
EN_RU_S decompression (KB)
Количество операций, шт
5000000
4000000
3000000
2000000
1000000
0
20 КБ
40 КБ
60 КБ
80 КБ
100 КБ
Размер файла
Huffman
Shannon-Fano

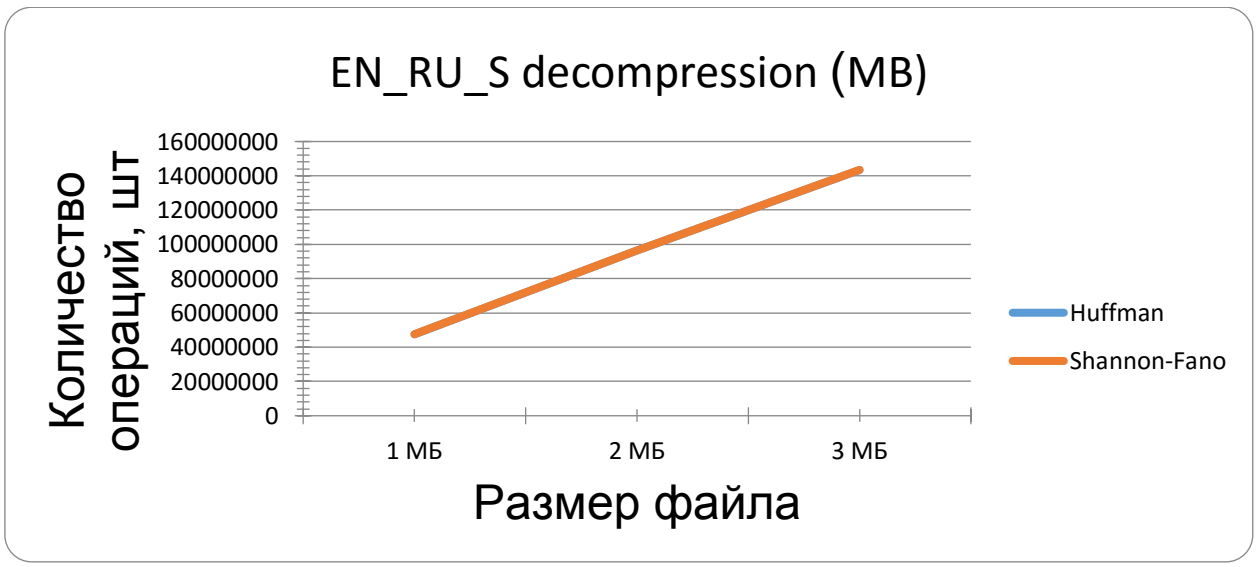
EN_RU_S decompression (MB)
Количество операций, шт
160000000
140000000
120000000
100000000
80000000
60000000
40000000
20000000
0
1 МБ
2 МБ
3 МБ
Размер файла
Huffman
Shannon-Fano

- Зависимость количества операций (ось OY) от размера набора символов (ось OX) на файлах максимального размера (3 Мб) для каждого алгоритма архивирования / разархивирования (цвет линии):

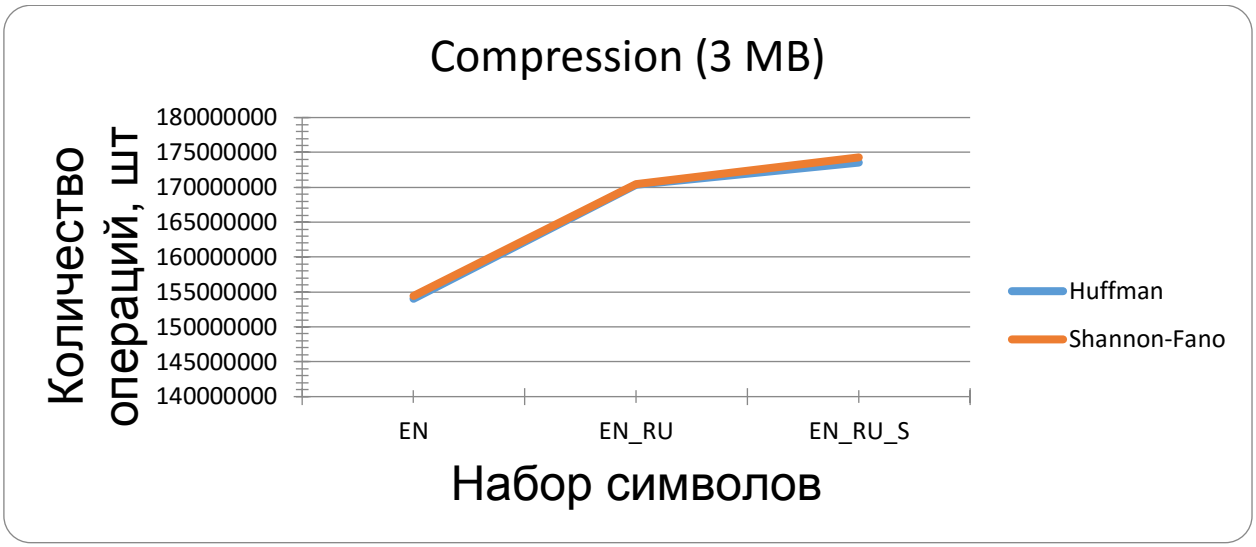

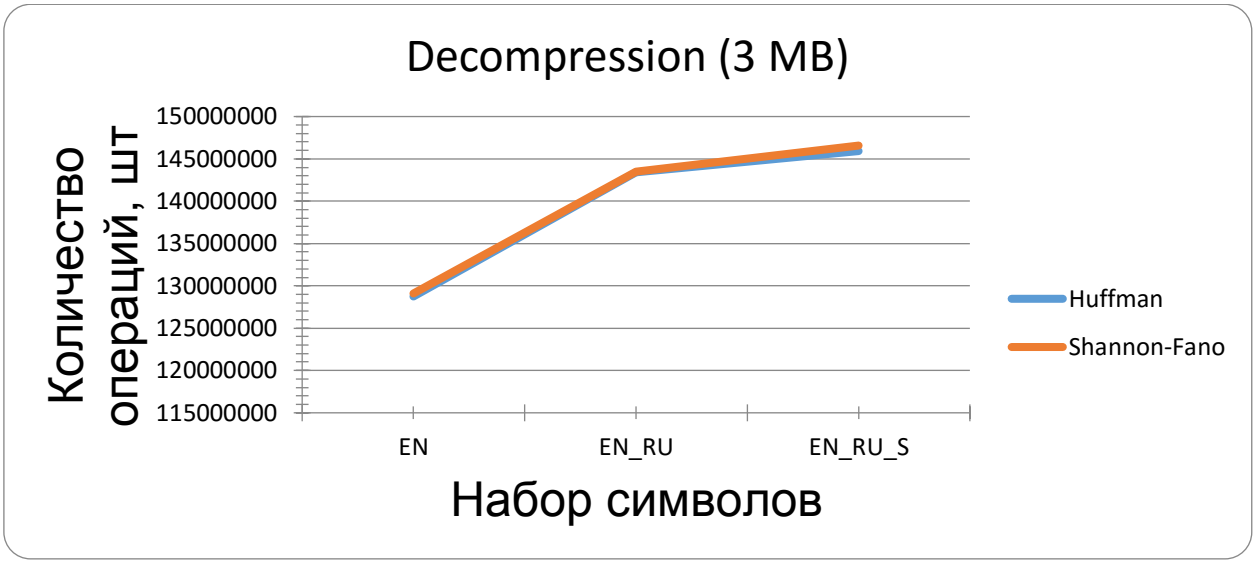

Сравнительный анализ методов (сложность, «+» и «–»)

Критерий	**Алгоритм Хаффмана**	**Алгоритм Шеннона-Фано**	**Комментарий**
Сложность архивации в теории	O(N+KlogK)	O(N+KlogK)	N – число символов в тексте архивируемого файла K – число уникальных символов (алфавит)
Сложность архивации в программной реализации	O(N+K^2)	O(N+KlogK)	Программная реализация алгоритма Хаффмана отличается от теоретической (программу можно оптимизировать). Однако из-за того, что число символов алфавита K на порядок меньше числа N (количество символов в файле), данная недоработка несильно сказалась на результате эксперимента.
Сложность деархивации	O(N+K)	O(N+K)	Сложность деархивации в разработанной программе совпадает с теоретической.
Оптимальное кодирование	Да	Не всегда	Из-за неоднозначности разбиения набора символов на группы, алгоритм Шеннона-Фано не всегда дает на выходе оптимальное бинарное дерево
Коэффициент сжатия	Выше	Ниже	Следствие возможной не оптимальности построения бинарного дерева. Большая эффективность алгоритма Хаффмана также видна на графиках, приведенных в пункте «Результаты эксперимента», где прямая алгоритма Хаффмана лежит немного ниже прямой алгоритма Шеннона-Фано.
Количество элементарных операций	Меньше	Больше	Количество элементарных операций немного меньше у алгоритма Хаффмана. Это также следует из возможной не оптимальности построения бинарного дерева.
Время исполнения	Меньше (в теории)	Больше (в теории)	Следствие возможной не оптимальности построения бинарного дерева, аналогично коэффициенту сжатия.
Способ построения дерева	Снизу вверх	Сверху вниз	см. п. «Описание алгоритмов»

Заключение (краткие выводы)

- Исследование алгоритмов сжатия Хаффмана и Шеннона-Фано было успешно проведено. На языке C++ была разработана программа для архивации и разархивации файлов с помощью данных алгоритмов. Было проведено тестирование работы программы на файлах различного объема (20 КБ – 3 МБ) с измерением количества элементарных операций, коэффициента сжатия и времени исполнения программы.
- Оба алгоритма обладают довольно большим коэффициентом сжатия, который увеличивается с увеличением размера исходного файла. Так файл объемом 3 МБ сжимается до примерно до 2.4 МБ, т.е. k = 3.0/2.4 = 1.25.
- Количество операций при архивации/разархивации алгоритмом Шеннона-Фано больше у алгоритма Хаффмана, т.к. бинарное дерево кодов символов не всегда строится однозначно. Именно поэтому на практике алгоритм Шеннона-Фано используется редко.
- Разница в количестве минимальных операций и времени выполнения между алгоритмами оказалась минимальна при тестировании файлов, соответствующих спецификации задания, т.к. алгоритм Шеннона-Фано на них строит оптимальные деревья или же очень близкие к оптимальным. Однако это будет происходить не всегда, поэтому алгоритм Хаффмана является наиболее эффективным и универсальным.
- Сложность обоих алгоритмов сжатия сравнима с O(N + KlogK), где K – число символов алфавита, а N – общее число символов в исходном файле. Это подтверждают графики, приведенные в разделе «Результаты эксперимента».
- Сложность деархивации обоих алгоритмов – O(N + K)

Использованные источники

[1] Новиков Ф. А. Дискретная математика для программистов: Учебник для вузов. 3-е изд. — СПб.: Питер, 2009. ISBN 978-5-91180-759-7

[2] Кормен, Томас Х., Лейзерсон, Чарльз И., Ривест, Рональд Л., Штайн, Клиффорд. Алгоритмы: построение и анализ, 2-е издание: Пер. с англ. М.: Издательский дом "Вильямс", 2005. ISBN 5-8459-0857-4

[3] [Электронный ресурс]// URL: https://neerc.ifmo.ru/wiki/index.php?title=Алгоритм_Хаффмана (Дата обращения: 3.12.2016, режим доступа: свободный)

[4] [Электренноый ресурс]// URL: https://en.wikipedia.org/wiki/Shannon–Fano_coding (Дата обращения: 3.12.2016, режим доступа: свободный)